

# 강화학습 기반 1인칭 시점 LOD 제어를 통한 고품질·고효율 시뮬레이션 렌더링

## Learning What to Render in First-Person View: Visibility-Aware Level-of-Detail Control for Quality-Preserving Efficient Rendering

### 요약

근래 Physical AI, 자율주행 및 로봇틱스 분야에서는 실제 환경 데이터 수집의 높은 비용, 안전성 문제, 희귀 상황 재현의 한계로 인해 3D 시뮬레이션 기반 학습이 필수적인 연구 패러다임으로 자리 잡고 있다. 그러나 모든 객체를 높은 수준의 디테일(Level of Detail, LOD)로 렌더링할 경우 연산 병목과 프레임 저하가 발생하고, 낮은 LOD를 일괄 적용하면 에이전트의 1인칭 관측에서 핵심 시각 정보가 손실되어 학습 불안정성과 실 환경 성능 저하로 이어질 수 있다. 본 연구는 이러한 렌더링 효율과 관측 품질 간의 상충 관계를 고려한 강화학습 기반의 1인칭 시점 적응형 LOD 제어 프레임워크를 제안한다. 제안 방법은 객체의 거리·화면 내 크기·가시 영역 비율·현재 FPS를 상태로 활용하고, 시각적 품질과 FPS 안정성을 함께 고려하는 보상 함수를 통해 LOD 제어 정책 신경망을 학습한다. 실험 결과, 고정 LOD 방식 대비 평균 FPS와 프레임 안정성을 향상시키면서도 에이전트 관점의 핵심 시각 정보를 효과적으로 보존함을 확인하였다.

### 1. 서론


근래 Physical AI, 자율주행, 로봇틱스 등 다양한 분야에서 3D 시뮬레이션 기반 학습의 중요성이 높아지고 있으나, 대규모 장면을 실시간으로 렌더링하는 과정에서 시각적 품질과 렌더링 효율 간의 상충 관계가 핵심 과제로 부각되고 있다. 그림 1-(b)와 같이 객체를 높은 수준의 디테일(Level of Detail, LOD)로 처리하는 것은 시각적 품질을 보장하지만 프레임 저하와 연산 병목을 유발하며, 낮은 LOD(그림 1-(a))는 FPS 성능을 확보하는 대신 객체의 형상 및 표면 디테일 손실을 초래한다.

기존의 LOD 제어 방식 [1, 2]은 주로 거리 기반(distance-based) 또는 규칙 기반(rule-based)으로, 카메라와 객체 사이의 거리 혹은 사전에 정의된 기준에 따라 디테일 수준을 조정한다. 이러한 방식은 단순하고 효율적이지만, 동일한 거리의 객체라도 화면 내 크기나 가림 정도에 따라 달라지는 에이전트의 실제 시각적 중요도를 충분히 반영하지 못한다. 특히 카메라 기반 입력을 사용하는 강화학습 환경에서는 큰 폭의 LOD 변화로 인한 입력 분포의 불연속적 변화가 정책 학습의 안정성과 성능 저하로 이어진다.

이에 본 연구는 다음의 핵심 연구 질문을 다루고자 한다.

“에이전트의 1인칭 관측에서 객체의 거리, 화면상 크기, 객체 가림, 가시성, 현재 FPS 등을 바탕으로, 시각적 중요도가 높은 객체의 품질을 유지하면서 렌더링 성능을 최적화하는 LOD 제어 정책을 학습할 수 있는가?”

이를 위해 본 연구는 강화학습 기반의 LOD 제어 프레임워크를 제안한다. 제안하는 방법은 에이전트의 카메라 시점에서 객체별 상태를 관측하고 신경망을 통해 LOD 제어 영역을 추정하여 각 객체의 LOD 수준을 동적으로 조정하며, 렌더링 성능과 시각적



(a) LOD-저품질, 52.7 FPS

(b) LOD-고품질, 33.4 FPS

그림 1: LOD 수준에 따른 시각적 품질 비교

품질을 동시에 고려하는 보상 함수를 통해 두 목표 간의 균형을 학습한다. 본 연구의 주요 기여는 다음과 같다.

- **강화학습 기반 LOD 제어 프레임워크 제안:** LOD 제어를 에이전트의 1인칭 시점 관측 품질과 렌더링 성능 사이의 trade-off를 최적화하는 순차적 의사결정 문제로 정의한다.
- **에이전트 관측 중요도 기반 상태 표현 설계:** 거리, 객체 크기, 가시 영역 비율, FPS 등을 활용하여 에이전트의 1인칭 시점에서 객체별 관측 중요도를 반영한 상태 표현을 제안한다.
- **가시성 및 FPS 안정성 기반 보상 설계:** 관측 가능한 중요 객체의 시각적 품질 저하를 억제하면서, FPS의 급격한 변동을 완화하도록 보상 함수를 설계한다.
- **고효율·고품질 시뮬레이션 렌더링 검증:** 고정 LOD 방식 대비 FPS 향상, 프레임 안정성 확보, 에이전트 관점의 주요 시각 정보 보존 효과를 실험적으로 확인한다.




그림 2: 강화학습 기반 1인칭 시점 LOD 제어 프레임워크

## 2. 강화학습 기반 LOD 제어 프레임워크

### 2.1 전체 방법론 개요

본 연구는 강화학습 기반으로 LOD(Level-of-Detail) 변경 범위를 동적으로 조정하여, 렌더링 성능과 시각적 품질 간의 균형을 최적화하는 프레임워크를 제안한다. 전체 구조는 그림 2와 같이 Environment-Agent 상호작용 루프로 구성된다.

에이전트는 레이트레이싱(Ray-tracing)을 통해 환경을 관측하고, 해당 정보를 바탕으로 LOD 적용 범위를 조정하는 액션을 추정한다. 이후 환경은 변경된 LOD 설정을 반영하여 다시 렌더링되며, 그 결과는 다음 상태 및 보상으로 피드백된다.

### 2.2 상태(State) 정의

에이전트는 카메라 시점에서 환경 내 각 객체의 기하학적·가시성 정보를 실시간으로 관측한다. 객체  $i$ 에 대한 관측 벡터  $O_i$ 는 다음과 같이 정의한다.

$$O_i = (d_i, r_i, S_i, V_i, LOD_i) \quad (1)$$

여기서  $d_i$ 는 에이전트와 객체 간의 유클리드 거리,  $r_i$ 는 객체의 bounding sphere 반지름,  $S_i$ 는 객체의 상대적 크기,  $V_i$ 는 가시 영역 비율,  $LOD_i$ 는 현재 적용된 LOD 수준을 나타낸다.

**객체의 상대적 크기.**  $S_i$ 는 "에이전트 시점에서 객체가 화면에서 차지하는 상대적 크기"를 나타내며, 카메라와의 거리  $d_i$  및 객체 반지름  $r_i$ 를 이용하여 다음과 같이 정의한다. 즉, 객체가 크고 가까울수록 값이 커지고, 멀거나 작을수록 값이 작아진다.

$$S_i = \left( \frac{r_i}{d_i} \right)^2 \quad (2)$$

**가시 영역 비율.** 객체가 카메라 시야 내에 존재하더라도 다른 객체에 의해 부분적으로 가려질 수 있다. 따라서, 이러한 가림 현상을 반영하기 위해, 객체 표면에서 균일하게 샘플링된 점들 중 카메라로부터의 ray casting을 통해 실제로 관측 가능한 점의 비율로  $V_i$ 를 정의한다.

$$V_i = k \cdot \frac{N_i^{\text{visible}}}{N_i^{\text{total}}} \quad (3)$$

이때,  $N_i^{\text{total}}$ 은 객체 표면에서 샘플링된 점의 총 개수,  $N_i^{\text{visible}}$ 은 그 중 실제로 관측 가능한 점의 개수이며,  $k$ 는 비율 조정 계수이다. 노출된 객체는  $V_i \approx k$ , 완전히 가려진 객체는  $V_i \approx 0$ 이 된다.

상태 표현 벡터  $s$ 는 장면 내 객체들의 관측 벡터, 객체 수  $N$ , 그리고 현재 시뮬레이션의 프레임률 FPS로 구성된다.

$$s = \{O_1, O_2, \dots, O_N, N, \text{FPS}\} \quad (4)$$

### 2.3 행동(Action) 정의

본 연구에서의 에이전트의 액션  $a$ 는  $LOD_{LQ}$ (저품질)에서  $LOD_{HQ}$ (고품질)으로 조정할 영역을 결정하는 두 경계값  $r_1, r_2$  ( $r_1 \leq r_2$ )로 정의된다 (그림 3). 이후 산출된 영역을 대상으로 LOD의 조정이 이루어진다.

$$a = (r_1, r_2) \quad (5)$$

이를 통해 에이전트는 매 스텝마다 시각적 중요도에 따라  $LOD_{HQ}$ 의 적용 범위를 동적으로 조정한다.




그림 3: LOD 조정 대상 범위

### 2.4 보상 함수(Reward Function) 정의

보상 함수는 렌더링 성능 향상과 시각적 품질 보존이라는 두 목표를 동시에 최적화하도록 설계하며, 다음과 같이 정의한다.

$$R = \alpha \cdot \mathcal{L}_{\text{perceptual}} - \beta \cdot |\Delta \text{FPS}| \quad (6)$$

여기서  $\Delta \text{FPS}$ 는 이전 스텝 대비 프레임률 변화량이며,  $\alpha$ 와  $\beta$ 는 각각 시각적 품질과 렌더링 성능 간의 균형을 조절하는 가중치이다.

시각적 품질 손실  $\mathcal{L}_{\text{perceptual}}$ 은 에이전트 시점에서 시각적으로 중요한 객체에 대한 LOD 저하 정도를 다음과 같이 정량화한다.

$$\mathcal{L}_{\text{perceptual}} = \sum_{i \in \mathcal{O}_{\text{visible}}} S_i \cdot V_i \cdot D_i \quad (7)$$

여기서  $D_i$ 는 객체  $i$ 에 적용된 LOD 수준에 따른 품질 지표로, 고품질 적용 시 양의 값, 저품질 적용 시 음의 값을 가진다.

$$D_i = \begin{cases} 1 & \text{if LOD}_i = \text{High Quality} \\ -1 & \text{if LOD}_i = \text{Low Quality} \end{cases} \quad (8)$$

이 보상 구조는 화면 내 크기( $S_i$ )가 크고 실제로 관측 가능한( $V_i$ ) 객체의 LOD 저하에 더 큰 패널티를 부여함으로써, 에이전트 시점에서의 시각적 중요도를 효과적으로 반영한다.

## 2.5 LOD 제어 정책 신경망

정책 신경망  $\pi_\theta$ 는 현재 상태  $s$ 를 입력으로 받아 LOD 제어 범위  $a$ 를 출력하는 신경망으로 정의된다.

$$a = \pi_\theta(s) \quad (9)$$

정책신경망  $\pi_\theta$ 는 상태 벡터  $s$  내 각 객체의 관측 벡터  $O_i$ 를 기반으로 장면 전체의 시각적 중요도 분포를 추정하고, 이를 입력으로 렌더링 성능과 관측 품질을 동시에 최적화하는 LOD 적용 범위  $(r_1, r_2)$ 를 결정한다. 학습은 보상  $R$ 의 기댓값을 최대화하는 방향으로 파라미터  $\theta$ 를 학습하는 On-policy 기반 강화학습 방법론인 Proximal Policy Optimization (PPO) [3] 방법을 활용한다.

## 3. 시뮬레이션 및 학습 결과

### 3.1 Experimental Setup

본 연구에서는 다양한 크기와 형태를 가지는 객체들로 구성된 3D 환경에서 실험을 수행하였다. 환경은 다수의 정적 객체와 배경 요소로 구성되며, 에이전트는 카메라를 통해 장면을 관측한다. 환경 내 객체들은 서로 다른 거리와 배치를 가지며, 일부 객체는 다른 객체에 의해 부분적으로 가려지는 상황을 포함한다.

시뮬레이션 및 학습 환경은 Unreal Engine 5와 PyTorch를 이용하여 구축하였으며, 비교 대상으로는 모든 객체에 고품질 및 저품질 LOD 일괄 적용하는 Fixed LOD<sub>HQ</sub>와 Fixed LOD<sub>LQ</sub>를 설정하였으며, 제안하는 방법론(RL-LOD)과 비교·분석하였다.

### 3.2 Adaptive LOD Control Results

제안하는 강화학습 기반 LOD 제어 방법을 적용한 결과를 그림 4에 나타내었다. 에이전트는 카메라 시점에서 중요도가 높은 객체에는 높은 LOD를 유지하고, 상대적으로 중요도가 낮은 객체에는 낮은 LOD를 적용하는 정책을 학습한다. 특히 다음과 같은 경향이 관찰되었다:

- 카메라에 가까운 객체는 높은 LOD 유지



그림 4: Adaptive LOD control result. 에이전트 시점에서 시각적 중요도에 따라 객체별 LOD가 동적으로 조정된 결과를 보여준다.

표 1: 성능 비교 (Training steps : 570k)

| Method                        | Avg FPS | Min FPS |
|-------------------------------|---------|---------|
| Fixed LOD <sub>LQ</sub> (저품질) | 52.7    | 40.3    |
| Fixed LOD <sub>HQ</sub> (고품질) | 33.4    | 26.2    |
| Proposed RL-LOD (Ours)        | 45.2    | 36.8    |

- 화면에서 작은 영역을 차지하는 객체는 낮은 LOD 적용
- 다른 객체에 의해 가려진 객체는 낮은 LOD 선택

이러한 결과는 제안한 보상 함수가 단순한 거리 기반 기준을 넘어, 에이전트 시점에서의 시각적 중요도를 효과적으로 반영하는 LOD 제어 정책을 학습함을 보여준다.

### 3.3 Quantitative Results

제안하는 방법의 렌더링 성능을 정량적으로 평가하기 위해, 고정 LOD 방식과의 평균 FPS 및 최소 FPS를 비교하였다(표 1). 제안 방법은 고품질 고정 방식(Fixed LOD<sub>HQ</sub>) 대비 평균 FPS를 약 59% 향상시키고, 최소 FPS 또한 26.2에서 36.8로 크게 개선하여 프레임 안정성을 확보하였다. 저품질 고정 방식(Fixed LOD<sub>LQ</sub>)과 비교하면 FPS는 다소 낮으나, 에이전트 시점에서 시각적으로 중요한 객체의 고품질 렌더링을 유지함으로써 관측 품질 손실을 최소화한다. 이는 제안 방법이 렌더링 효율과 관측 품질 간의 균형을 효과적으로 달성함을 보여준다.

## 참고 문헌

- [1] K. H. Tan and D. Daman, "A review on level of detail," in *Proceedings of the International Conference on Computer Graphics, Imaging and Visualization (CGIV)*, 2004.
- [2] J. El-Sana and A. Varshney, "Generalized view-dependent simplification," in *Proceedings of Graphics Interface*, 1999.
- [3] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," in *arXiv preprint arXiv:1707.06347*, 2017.